



UNIVERSITÉ DE MBUJIMAYI – TSHIKAMA

Faculté / Département : [à compléter]

SOUTENANCE — Mémoire de Master 1 en Intelligence Artificielle

Assistant intelligent lexical bilingue Tshiluba – Français

Recherche et compréhension bidirectionnelle du vocabulaire à partir d'un corpus linguistique numérique

Diriger par : Théodore KABANGU

Présenté par : KABANGU KABEYA Henock & KALONJI MULUMBA Olivier

Corpus CILUBA – FRANÇAIS · FastAPI · Ollama · Qwen2.5 0.5B

Une langue vivante, des ressources numériques dispersées

Le constat

- Le Tshiluba est parlé par des millions de locuteurs en RDC.
- Les ressources lexicales numériques existantes restent limitées, dispersées et difficiles à interroger rapidement.

Notre point de départ

- Un corpus Tshiluba–Français structuré : colonnes CILUBA, FRANCAIS, SCORE, SENTIMENT, NATURE.
- Une base exploitable pour construire un système de recherche assisté par IA.

Pourquoi maintenant

Les outils IA génériques (traducteurs, chatbots) ne couvrent pas ou mal le Tshiluba, et ne s'appuient sur aucune source vérifiée pour cette langue. Un système dédié, fondé sur un corpus contrôlé, comble ce manque plutôt que de laisser un LLM générer librement des réponses non vérifiables.

Six difficultés concrètes rencontrées par l'utilisateur

- Mot français connu, équivalent Tshiluba inconnu
- Mot Tshiluba connu, sens français inconnu
- Terme Tshiluba rencontré sans en comprendre le sens
- Besoin d'informations linguistiques (nature, etc.)
- Besoin d'une explication ou d'un exemple d'usage
- Ressources dispersées, difficiles à interroger vite

Problème scientifique et informatique

Comment concevoir un système intelligent capable de faciliter la recherche et la compréhension bidirectionnelle du vocabulaire Tshiluba–Français à partir d'un corpus linguistique numérique, tout en limitant les réponses non fondées ?

Une hypothèse claire à vérifier

Question de recherche

Dans quelle mesure une architecture combinant recherche lexicale structurée et génération de langage contrôlée permet-elle de fournir des réponses bidirectionnelles fiables sur un corpus Tshiluba–Français à ressources limitées ?

H1 Hypothèse 1

Une recherche prioritaire dans le corpus réduit le risque de réponses non fondées, comparé à une génération libre par le LLM seul.

H2 Hypothèse 2

Un modèle de langage léger (Qwen2.5 0.5B) suffit aux tâches de reformulation et d'explication, sans nécessiter un modèle entraîné spécifiquement sur le Tshiluba.

Un objectif général, six objectifs spécifiques

Objectif général

Concevoir un assistant intelligent capable de faciliter la recherche et la compréhension bidirectionnelle du vocabulaire Tshiluba–Français à partir d'un corpus lexical numérique.

1

Constituer et nettoyer un corpus lexical bilingue

2

Permettre une recherche bidirectionnelle (FR ↔ Tshiluba)

3

Structurer les réponses à partir des données du corpus

4

Utiliser Qwen pour l'explication, la reformulation, les exemples

5

Limiter les hallucinations en priorisant le corpus

6

Exposer les fonctionnalités via une API FastAPI sécurisée (JWT)

Pourquoi les solutions actuelles ne suffisent pas



Lexiques papier / listes éparses

Non centralisés, non interrogeables rapidement, difficiles à maintenir à jour.



Traducteurs génériques

Couvrent mal ou pas le Tshiluba ; aucun contrôle sur la fiabilité du résultat.



Chatbots IA génériques

Peuvent halluciner des traductions absentes de leurs données ; aucune traçabilité de la source.

Ce qui manque

Un système dédié au Tshiluba, fondé sur un corpus vérifié comme source de vérité, où la génération par un modèle de langage vient compléter — et non remplacer — la recherche lexicale.

Pas un simple « Utilisateur → Qwen → réponse »

Utilisateur → Qwen → réponse — architecture insuffisante (aucune vérification, risque d'hallucination)



Ce que cela change

Le corpus est interrogé en premier et sert de source de vérité. Qwen n'intervient qu'ensuite, pour reformuler, expliquer ou illustrer un résultat déjà identifié — jamais pour inventer une traduction absente du corpus.

Sept couches, chacune pour une raison précise




Pourquoi chaque brique


FastAPI expose et sécurise l'accès ; le corpus reste la référence linguistique ; le moteur de recherche garantit qu'une réponse existante n'est jamais reformulée par erreur en une invention ; Ollama exécute Qwen localement, sans dépendance cloud ; Qwen sert uniquement à la mise en forme et à l'explication, jamais à décider seul d'une traduction ; JWT évite un usage anonyme d'une ressource de calcul limitée.

De la question à la réponse — les deux cas possibles

Cas 1 — le terme est trouvé



Cas 2 — le terme est absent du corpus



Règle stricte

Lorsque le terme est absent, le système l'indique explicitement à l'utilisateur — Qwen n'est jamais sollicité pour inventer une traduction non présente dans le corpus.

Deux rôles distincts, jamais confondus



Le corpus — source de vérité

- Contient les équivalences lexicales réelles (CILUBA ↔ FRANCAIS)
- Fournit nature grammaticale, score et sentiment lorsqu'ils sont disponibles
- Toute réponse factuelle doit d'abord s'appuyer sur lui



Qwen2.5 0.5B — outil de langage

- Comprend la demande, reformule, explique, génère un exemple
- N'est PAS notre source de connaissances Tshiluba
- Risque d'hallucination s'il génère librement sans passer par le corpus

Pourquoi cette séparation est plus fiable

Un LLM généraliste comme Qwen2.5 0.5B n'a pas été entraîné spécifiquement sur le Tshiluba : le laisser générer librement une traduction reviendrait à prendre le risque d'une réponse inventée. La recherche préalable dans le corpus élimine ce risque pour toute information factuelle.

Six scénarios concrets

1 Français → Tshiluba

« Comment dit-on maison en Tshiluba ? » → recherche corpus → équivalent.

2 Tshiluba → Français

« Que signifie [mot] en français ? » → recherche → équivalent.

3 Terme inconnu

« Je ne connais pas ce mot. » → recherche → résultat + explication éventuelle.

4 Information linguistique

« Quelle est sa nature grammaticale ? » → colonne NATURE si disponible.

5 Explication

« Explique-moi ce mot simplement. » → Qwen génère l'explication.

6 Exemple d'usage

« Donne-moi un exemple. » → Qwen génère, si pertinent, un exemple.

API REST ≠ FastAPI, et deux routes réelles

REST vs FastAPI

REST est un style d'architecture pour exposer des ressources via HTTP. FastAPI est le framework Python qui implémente ce style ici : il définit les routes, valide les données et gère la sécurité.

1 POST /login

- Rôle : authentifier l'utilisateur
- Entrée : identifiants
- Sortie : jeton JWT
- Sécurité : requis pour accéder à /generate

2 POST /generate

- Rôle : traiter la demande (recherche + génération si besoin)
- Entrée : prompt + JWT
- Sortie : réponse structurée (JSON)
- Sécurité : accès protégé par Authorization: Bearer

Stack

Python 3.11 · FastAPI · Ollama · Qwen2.5:0.5B · corpus CSV nettoyé · JWT

Un corpus nettoyé, des métriques à mesurer

2 982

lignes initiales

592

doublons supprimés

2 388

paires uniques

Métriques réellement mesurables (à compléter)

Taux de recherche réussie · taux de correspondance exacte · temps moyen de réponse · nombre de requêtes correctement traitées · taux de termes absents du corpus · qualité perçue des réponses générées par Qwen.

Exemple de démonstration :

INPUT → "Comment dit-on maison en Tshiluba ?"

TRAITEMENT → recherche dans le corpus (colonne FRANCAIS = «maison»)

OUTPUT → équivalent CILUBA trouvé, réponse structurée renvoyée

Un système honnête sur ses limites actuelles



Limites

- Corpus de taille limitée, principalement lexical (mots, peu de phrases)
- Couverture lexicale incomplète, risque d'ambiguïté linguistique
- Qwen2.5 0.5B : capacités réduites, risque d'hallucination en génération libre
- Contexte parfois absent pour certains termes



Perspectives

- Enrichir le corpus (phrases, expressions) et le valider avec des locuteurs
- Recherche sémantique, RAG si nécessaire
- Fine-tuning / LoRA d'un modèle adapté au Tshiluba
- Interface web/mobile, reconnaissance et synthèse vocale

Positionnement honnête

Le système est présenté comme un assistant lexical bilingue, et non comme un traducteur neuronal complet de phrases — cohérent avec la nature actuelle du corpus.

Ce que nous avons réellement apporté

- Constitution et nettoyage d'une ressource lexicale Tshiluba–Français
- Mise en place d'une recherche bidirectionnelle
- Intégration d'un LLM léger exécuté localement (Qwen2.5 0.5B + Ollama)
- Conception d'une API sécurisée (FastAPI + JWT)
- Architecture combinant recherche lexicale et génération contrôlée
- Mécanisme limitant les réponses non fondées

Merci pour votre attention